

## 2<sup>η</sup> Σειρά Ασκήσεων

Δημήτριος Τσιομπίκας

ΑΜ : 3180223

### Άσκηση 1

#### Ερώτημα 1

i) a)

1<sup>η</sup> Επερώτηση σε SQL :

```
SELECT *  
FROM R  
WHERE a = 2;
```

Έχουμε :

$T(R) = 1000000$

$B(R) = 20000$

$V(R,A) = n$

Έστω  $B(X)$  best case scenario

Άρα  $B(X) = B(R)/V(R,A) = 20000/n$  (για clustered index scan)

b)

2<sup>η</sup> Επερώτηση σε SQL :

```
SELECT *  
FROM R  
WHERE k <= a AND a <= l;
```

Εφόσον ανήκουν  $n/10$  τιμές εδώ το best case scenario θα είναι :

$B(X) = B(R)/V(R,A)/10 = 20000/n/10 = 200000/n$  (για clustered index scan)

ii)

a)

Εδώ θα πάρουμε το worst case scenario (Έστω  $T(X)$ ).

Άρα  $T(X) = T(R) / V(R,A) = 1000000/n$  (με non-clustered index scan για την 1<sup>η</sup> επερώτηση)

b)

$T(X) = T(R) / V(R,A) / 10 = 1000000/n/10 = 10000000/n$  (non-clustered index scan , 2<sup>η</sup> επερώτηση)

## Ερώτημα 2

Γνωρίζουμε ότι το Table Scan έχει κόστος  $B(R)$ .

a)

Για την 1<sup>η</sup> επερώτηση , μας συμφέρει να το χρησιμοποιήσουμε στην εξής περίπτωση :

$$T(R) / V(R,A) < B(R) \Rightarrow 1000000/n < 20000 \Rightarrow 20000 * n > 1000000 \Rightarrow$$

$n > 50$ . Δηλαδή όταν οι διακριτές τιμές είναι περισσότερες από 50.

b)

Για την 2<sup>η</sup> επερώτηση έχουμε το εξής :

$$T(R) / V(R,A)/10 < B(R) \Rightarrow (1000000/1) / n/10 < 20000 \Rightarrow 10000000/n < 20000 \Rightarrow 20000 * n > 10000000 \Rightarrow n > 500.$$

Άρα το απλό ευρετήριο συμφέρει αν έχουμε περισσότερες από 500 διακριτές τιμές.

## Άσκηση 2

### Ερώτημα 1

Έστω ότι η επερώτηση λέγεται Q.

Άρα ψάχνουμε το  $T(Q)$ .

Εφόσον το διάστημα τιμών στους πίνακες είναι 20 διακριτές τιμές μπορούμε να πούμε ότι :

$$V(R,B) = 20$$

$$V(S,B) = 20$$

Επίσης μπορούμε να βρούμε το T των πινάκων ως εξής :

$$T(R) = 0 + 80 + 100 + 20 + 30 = 230 \text{ εγγραφές}$$

$$T(S) = 10 + 100 + 60 + 60 + 0 = 230 \text{ εγγραφές}$$

a)

Άρα με βάσει τα στατιστικά των ιστογραμμάτων έχουμε :

$$\begin{aligned} T(Q) = & T(R)[0-20] * T(S)[0-20] / \max\{V(R,B), V(S,B)\} + T(R)[21-40] \\ & * T(S)[21-40] / \max\{V(R,B), V(S,B)\} + T(R)[41-60] * T(S)[41- \\ & 60] / \max\{V(R,B), V(S,B)\} + T(R)[61-80] * T(S)[61-80] / \\ & \max\{V(R,B), V(S,B)\} + T(R)[81-100] * T(S)[81-100] / \\ & \max\{V(R,B), V(S,B)\} = 0 * 10 / 20 + 80 * 100 / 20 + 100 * 60 / 20 + \end{aligned}$$

$20 \cdot 60 / 20 + 30 \cdot 0 / 20 = 0 + 400 + 300 + 60 = 760$  πλειάδες θα εκτυπώσει.

b)

Και με ομοιόμορφη κατανομή έχουμε :

$$T(Q) = T(R) \cdot T(S) / V(R,B) = 230 \cdot 230 / 100 \\ = 52900 / 100 = 529 \text{ πλειάδες θα εμφανίσει.}$$

(Χρησιμοποιούμε το  $V(R,B)$  επειδή  $V(R,B) = V(S,B)$  οπότε δεν έχει σημασία ποιο από τα 2 θα χρησιμοποιήσουμε, το  $V(R,B)$  γίνεται 100 γιατί τώρα δεν μας νοιάζουν τα διαστήματα).

### Άσκηση 3

#### Ερώτημα 1

Γνωρίζουμε ότι :

$$T(R) = 20000$$

$$T(S) = 45000$$

$$B(R) = 25$$

$$B(S) = 30$$

$$M = 41$$

a)

NLJ (Block based) Cost =  $B(R) + (B(R) / M - 1) * B(S) = 25 + (25/40) * 30 = 25 + 1 * 30 = 55$  I/Os

b)

SMJ Cost =  $5 * (B(R) + B(S)) = 5 * 25 + 30 = 155$  I/Os

c)

Hash Join Cost =  $3 * (B(R) + B(S)) = 3 * 25 + 30 = 105$  I/Os

## Ερώτημα 2

1<sup>ος</sup> τρόπος :

Μπορούμε να χρησιμοποιήσουμε τη βελτιωμένη έκδοση του SMJ με το εξής κόστος :

SMJ Cost =  $3 * (B(R) + B(S)) = 3 * 25 + 30 = 105$  I/Os

2<sup>ος</sup> τρόπος :

Μπορούν οι σχέσεις εισόδου να ταξινομηθούν προτού εκτελεστεί ο αλγόριθμος με αποτέλεσμα να χουμε το εξής κόστος :

$$SMJ \text{ Cost} = B(R) + B(S) = 25 + 30 = 55 \text{ I/Os}$$

#### Άσκηση 4

Έχουμε τα εξής δεδομένα :

$$T(\Delta\text{ANEIZOMENOI}) = 10000$$

$$B(\Delta\text{ANEIZOMENOI}) = 1000$$

$$T(\text{BIBΛΙΑ}) = 50000$$

$$B(\text{BIBΛΙΑ}) = 5000$$

$$T(\Delta\text{ANEISMΟΙ}) = 300000$$

$$B(\Delta\text{ANEISMΟΙ}) = 15000$$

$$V(\text{BIBΛΙΑ}, \text{Εκδότης}) = 500$$

$$M = 20$$

1)  $\text{I/O Cost} = T(\text{BIBΛΙΑ}) / V(\text{BIBΛΙΑ}, \text{Εκδότης}) = 50000/500 = 100 \text{ I/Os}$  (ίδιο με τις πλειάδες)

Έστω ότι το Query λέγεται Q.

$T(Q) = T(\text{ΒΙΒΛΙΑ}) / V(\text{ΒΙΒΛΙΑ}, \text{Εκδότης}) = 50000/500 = 100$   
πλειάδες θα εκτυπώσει.

2) Αριθμός εγγραφών ανα σελίδα του πίνακα ΔΑΝΕΙΣΜΟΙ =  
 $T(\text{ΔΑΝΕΙΣΜΟΙ}) / B(\text{ΔΑΝΕΙΣΜΟΙ}) = 300000/15000 = 20$   
εγγραφές ανά σελίδα

Ας υποθέσουμε ότι το κόστος ανάγνωσης μέσω  
ευρετηρίου (έστω X) = 1.

$I/O \text{ Cost} = B(Q) + T(Q) * (X / \text{αριθμός εγγραφών ανα σελίδα του πίνακα ΔΑΝΕΙΣΜΟΙ}) = 100 + 100 * (1/20)$   
 $= 200 \text{ I/Os (στρογγυλοποιούμε το } 1/20 \text{ σε } 1)$

Έστω πως η σύζευξη λέγεται J

$T(J) = T(Q) * T(\text{ΔΑΝΕΙΣΜΟΙ}) / \max\{V(Q, KB), V(\text{ΒΙΒΛΙΑ}, KB)\}$   
 $= 100 * 300000 / 50000 = 600$  πλειάδες θα εκτυπώσει.

3) Ας υποθέσουμε ότι  $B(\text{ΠΚΔ}) = 1$

$I/O \text{ Cost} = I/O \text{ cost}(\text{INLJ}) + (B(\text{ΠΚΔ})/M-1) *$   
 $B(\text{ΔΑΝΕΙΣΜΟΙ}) = 200 + (1/19) * 1000 = 200 + 1*1000 =$   
1200 I/Os



Έστω L το όνομα της σύζευξης.

$$T(L) = T(J) * T(\Delta\text{ANEIZOMENOI}) /$$

$$\max\{V(J,K\Delta), V(\Delta\text{ANEIZOMENOI}, K\Delta)\} = 600 * 10000 / 10000 \\ = 600 \text{ πλειάδες θα εκτυπώσει.}$$

- 4) Εφόσον οι ηλικίες κυμαίνονται στα 7 εως 24 έτη θα έχουμε  $V(L, \text{Ηλικία}) = 24 - 7 + 1 = 18$ . Όμως, εμείς θέλουμε μόνο το εξής διάστημα  $[13, 19]$  άρα τις 7 από τις 18 τιμές. Γνωρίζουμε ότι για να πάρουμε μία από τις 18 διακριτές τιμές πρέπει να κάνουμε το εξής :
- $$T(L) / V(L, \text{Ηλικία}) = 600 / 18 = 34 \text{ πλειάδες.}$$

Όμως εμείς θέλουμε τις 7 από τις 18 άρα καταλήγουμε στο εξής αποτέλεσμα :


Έστω W η επερώτηση :

$$T(W) = 7 * 34 = 238 \text{ πλειάδες θα εκτυπώσει.}$$

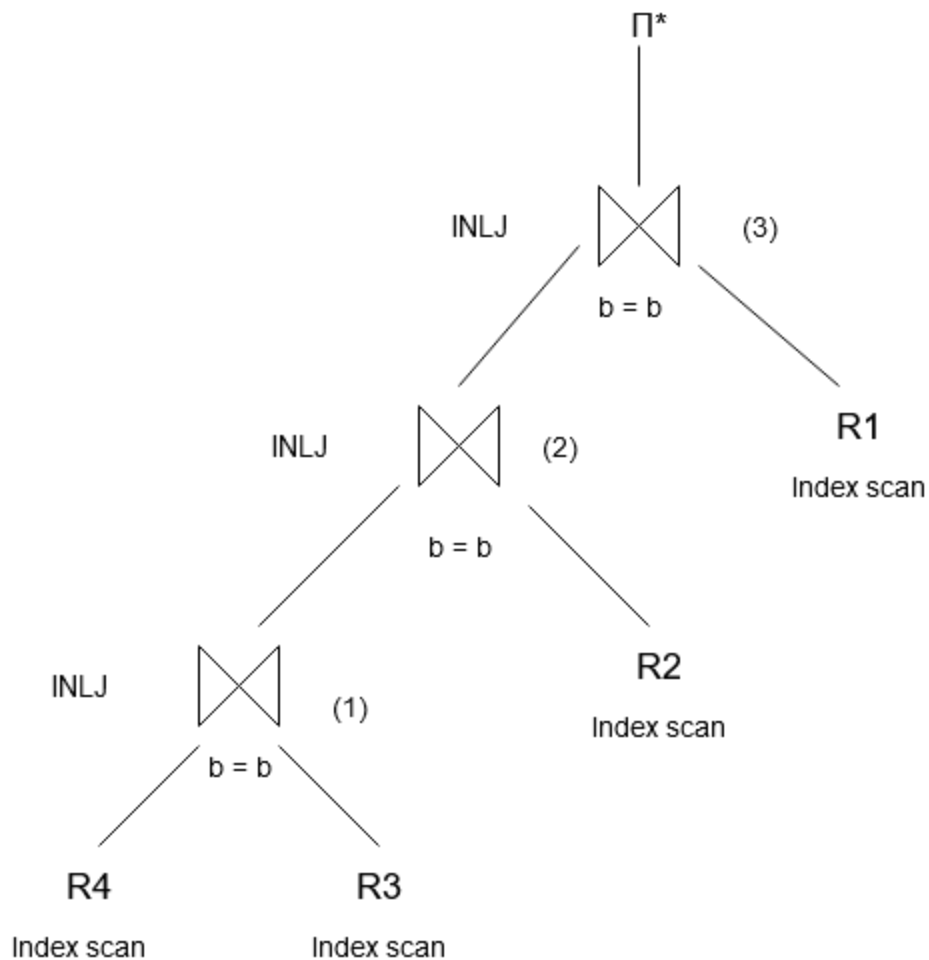
$$\text{I/O Cost} = 7 * 34 = 238 \text{ I/Os.}$$

## Άσκηση 5

### Ερώτημα 1



## Ερώτημα 2



Το πλάνο που πρότεινα είναι αποδοτικό διότι εφόσον κάθε γνώρισμα  $b$  έχει ευρετήριο συστάδων, ο αλγόριθμος INLJ (Indexed Nested Loop Join) είναι ο αποδοτικότερος για τις συζεύξεις.

### Ερώτημα 3

$$\text{I/O Cost (1)} = B(R4) + (B(R4) / M - 1) * B(R3)$$

$$\text{I/O Cost (2)} = B(1) + (B(1) / M - 1) * B(R2)$$

$$\text{I/O Cost (3)} = B(2) + (B(2) / M - 1) * B(R1)$$

Υποθέτω ότι ο R4 είναι το Outer relation και το R3 το inner relation , και ξεκινάω να βρίσκω τα I/Os με την περίπτωση INLJ για clustered indexes.